TAXIDEMAND NYC

Прогноз спроса на поездки такси по районам города

Проектный практикум · Тема №16 · Реальные данные NYC TLC

ЯНВАРЬ–ИЮНЬ 2024 · 30 ЗОН · 182 ДНЯ

01 Задача и практическая ценность

Решение ориентировано на аналитика и диспетчера автопарка

Что прогнозируем?

Число начинающихся поездок жёлтого такси
по зонам NYC TLC за сутки

Какое решение?

В каких районах ожидается повышенный спрос
и как распределить автомобили

02 Источники данных

Три разных формата, включая слабоструктурированные геоданные

NYC TLC

Parquet · дата поездки + зона отправления

Open-Meteo

JSON · температура, осадки и ветер

NYC Taxi Zones

GeoJSON / SHP · полигоны районов

Реальная загрузка проверена: 6 месяцев TLC, 182 дня погоды и геоданные зон. Синтетический режим доступен отдельно.

03 Архитектура сквозного решения

Из источников данных до прогноза и принятия решения



04 Обработка и защита от утечки

Единый расчёт признаков для обучения и эксплуатации

- Полная сетка «район × день», проверка пропусков и аномалий
- Лаги спроса: 1, 7, 14, 28 дней
- Оконные показатели: средние 7/28, разброс и минимум 7
- Календарные признаки и one-hot кодирование зон
- Погода только за предыдущий день: без знания будущего
- Отдельный тест: изменение y(t) не влияет на X(t)

05 Три прогнозные модели

Одинаковые временные периоды и две основные метрики плюс WAPE

SeasonalNaive

То же число поездок
7 дней назад

Ridge

Линейная модель
с регуляризацией

Boosting (HGB)

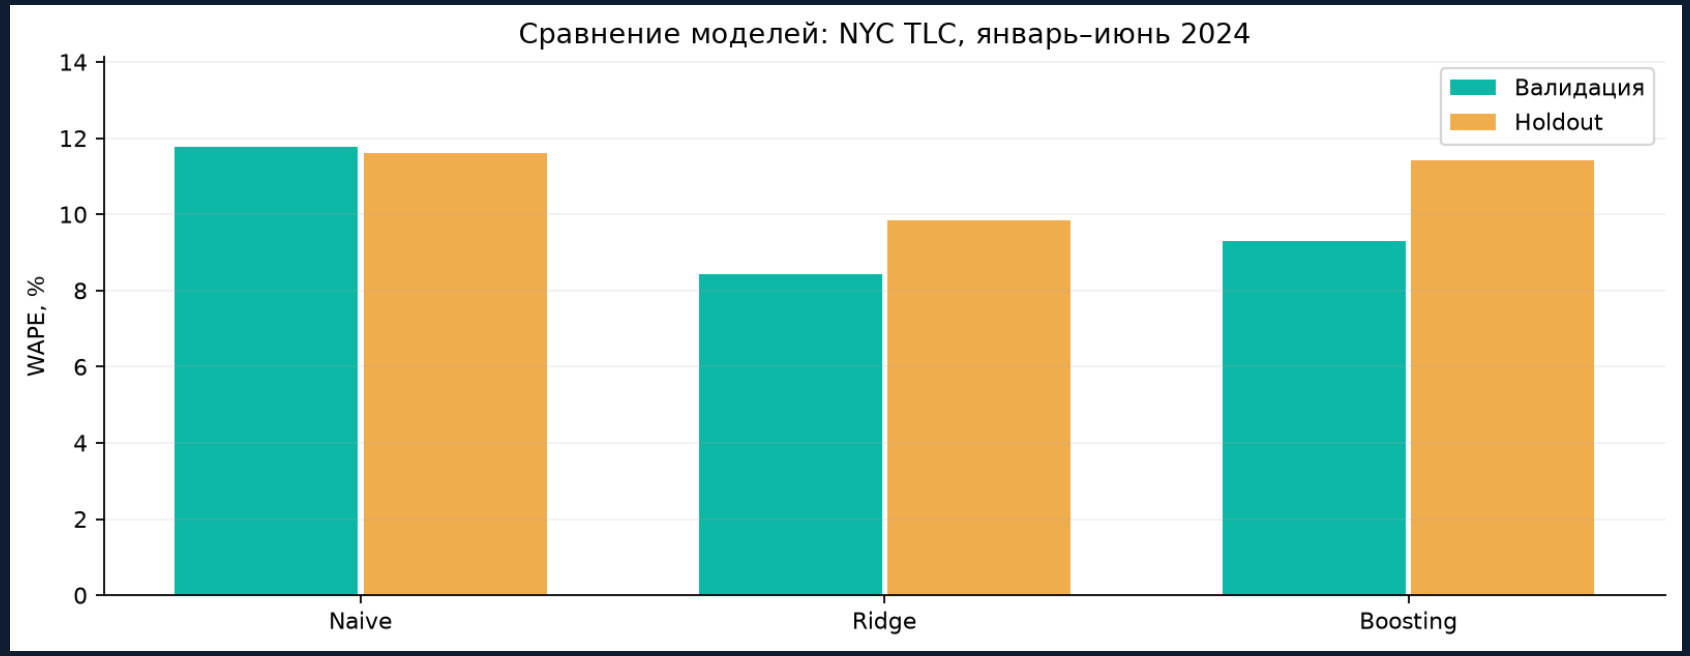
Нелинейные деревья
с бустингом

Разбиение: train 60% → validation 20% → holdout 20%

Подбор: 2 конфигурации × 3 хронологических фолда; seed = 42

06 Результаты сравнения

NYC TLC, 01.01–30.06.2024; 30 зон, 182 дня



9,85%

WAPE holdout
Ridge

MAE: 303,09 поездки/зона/день · RMSE: 418,40

07 Интерпретируемость

Объяснение не только глобального качества, но и любого выбранного прогноза

- Permutation importance: насколько ухудшится MAE после перемешивания
- Анализ абляции: исключить признак и переобучить модель
- Локальная декомпозиция прогноза: вклад каждой переменной
- Partial Dependence Plot для отдельного числового признака
- Сравнение важностей в двух частях валидационного периода

08 Мониторинг и воспроизводимость

Система фиксирует изменение поведения и хранит эксперименты

Контроль качества

- PSI лагов спроса > 0,4
- WAPE за 14 дней выше порога
- Имитация дрейфа без порчи базы
- Реестр моделей и откат

Журнал экспериментов

- 2 конфигурации × 3 time folds
- ID, параметры, seed, SHA-256
- MAE / RMSE / WAPE
- Воспроизведение по ID

09 Демонстрация работающего прототипа

Streamlit и CLI: полный цикл без ручного копирования файлов

01	**Данные**	Загрузка и журнал ошибок
02	**Обучение**	3 модели + validation / holdout
03	**Прогноз**	7 дней, разрез по зонам
04	**Контроль**	Объяснение, PSI, реестр

Тесты: 7 / 7 успешно · команда: make all

10 Выводы и честные ограничения

Прототип готов для автономной демонстрации

- Реализован полный цикл от источника до аналитического решения
- Есть три модели, интерпретация, мониторинг и повторение экспериментов
- На реальных данных выбрана Ridge, WAPE holdout 9,85%
- Загружены 6 месяцев TLC, погода и геоданные зон
- Ограничения: 30 зон, 6 месяцев, рекурсивный прогноз и будущая погода